


• Neuron jako lineární klasifikátor

$\xi < 0$

$\xi = 0$

$\xi > 0$



• přímka ($\xi = 0$) je definována w
vektorem \vec{w} (váhy neuronu)


• x_1, x_2, x_3 (mimo, kam ukazuje
vektor \vec{w}) mají $\xi > 0$; x_4, x_5, x_6
mají $\xi < 0$

• rovnice přímky (lineárního
klasifikátoru) je definována

$$\left| \frac{-w_0}{\|\vec{w}\|} \right|, \text{ kde } w_0 \text{ je bias}$$

• Aktivací funkce


- Unit step function: $\Delta(\xi) = \begin{cases} 1 & \xi \geq 0 \\ 0 & \xi < 0 \end{cases}$



- Logistic sigmoid: $\Delta(\xi) = \frac{1}{1 + e^{-\lambda \cdot \xi}}$; $\lambda \in \mathbb{R}$
parametr sklonosti




- Hyperbolic tangens: $\Delta(\xi) = \frac{1 - e^{-\xi}}{1 + e^{-\xi}}$




• Logické funkce (unit step function)


AND



OR



NOT



ADALINE

• Error function

$$E(\vec{w}) = \frac{1}{2} \sum_{k=1}^K (\vec{w} \cdot \vec{x}_k - d_k)^2 = \frac{1}{2} \sum_{k=1}^K \left(\sum_{i=0}^n w_i x_{ki} - d_k \right)^2$$

\Rightarrow cíl: najít \vec{w} takové, které minimalizuje $E(\vec{w})$

• Gradient of the error function

$$\nabla E(\vec{w}) = \left(\frac{\partial E}{\partial w_0}(\vec{w}), \dots, \frac{\partial E}{\partial w_n}(\vec{w}) \right)$$

• vektor v prostoru vah, který má ve směru nejmenšího svého chybové fee.

• vektory \vec{x}_k jsou fixované
 \nwarrow vstup

$\Rightarrow \nabla E(\vec{w}) = \vec{0} = (0, \dots, 0)$ znamená globální minimum chybové fee E

$$\frac{\partial E}{\partial w_k}(\vec{w}) = \frac{1}{2} \sum_{k=1}^K \frac{\partial}{\partial w_k} \left(\sum_{i=0}^n w_i x_{ki} - d_k \right)^2$$

$$= \sum_{k=1}^K (\vec{w} \cdot \vec{x}_k - d_k) x_{k,k}$$

$$\Rightarrow \nabla E(\vec{w}) = \left(\frac{\partial E}{\partial w_0}(\vec{w}), \dots, \frac{\partial E}{\partial w_n}(\vec{w}) \right) = \sum_{k=1}^K (\vec{w} \cdot \vec{x}_k - d_k) \vec{x}_k$$

• Learning algorithm

(Batch): $\vec{w}(t+1) = \vec{w}(t) - \epsilon \cdot \nabla E(\vec{w}(t)) = \vec{w}(t) - \epsilon \cdot \sum_{k=1}^K (\vec{w}(t) \cdot \vec{x}_k - d_k) \cdot \vec{x}_k$

(Online):

$$\vec{w}(t+1) = \vec{w}(t) - \epsilon(t) \cdot (\vec{w}(t) \cdot \vec{x}_k - d_k) \cdot \vec{x}_k$$

MULTI LAYER PERCEPTRON

- Notace :
 - X set vstupních neuronů (inputs)
 - Y set výstupních neuronů (outputs)
 - Z set všech neuronů ($X, Y \subseteq Z$)
 - i, j, \dots index neuronů :
 - f_j aktivní potenciál neuronu j ($\sum_{i \in j} w_{ji} y_i$)
 - y_j output neuronu j ($\sigma(f_j)$)
 - w_{ji} váha z neuronu i do neuronu j
 - $j \leftarrow$ set všech neuronů, které mají do j
 - $j \rightarrow$ set všech neuronů, které mají na j

• Error function

$\{(\vec{x}_z, \vec{d}_z) \mid z=1, \dots, p\}$ - Tréninková sada

$$E(\vec{w}) = \sum_{z=1}^p E_z(\vec{w}) \quad \dots \dots \text{suma přes všechny tréninkové příklady}$$

$$E_z(\vec{w}) = \frac{1}{2} \sum_{j \in Y} (y_j(\vec{w}, \vec{x}_z) - d_{zj})^2$$

• Learning algorithm (Batch)

$$w_{ji}^{(s+1)} = w_{ji}^{(s)} + \Delta w_{ji}^{(s)}$$

komponenta gradientu $\nabla E \Rightarrow$

$$\Rightarrow \vec{w}^{(s+1)} = \vec{w}^{(s)} - \epsilon(s) \cdot \nabla E(\vec{w}^{(s)})$$

$$\Delta w_{ji}^{(s)} = -\epsilon(s) \cdot \frac{\partial E}{\partial w_{ji}}(\vec{w}^{(s)}) \quad \dots \dots \text{update } w_{ji} \text{ v } s+1 \text{ kroku}$$

• Error function gradient

- pro hodič w_{ji} (váhy) $\frac{\partial E}{\partial w_{ji}} = \sum_{z=1}^p \frac{\partial E_z}{\partial w_{ji}}$

- a pro hodič $j \in Z \setminus X$ (neuron)

$$\frac{\partial E_z}{\partial y_j} = y_j - d_{zj} \quad \text{pro } j \in Y$$

- zde pro hodič z (examples)

$$\frac{\partial E_z}{\partial w_{ji}} = \frac{\partial E_z}{\partial y_j} \cdot \sigma'_j(f_j) \cdot y_i$$

$$\frac{\partial E_z}{\partial y_j} = \sum_{n \in j \rightarrow} \frac{\partial E_z}{\partial y_n} \cdot \sigma'_n(f_n) \cdot w_{nj}$$

pro $j \in Z \setminus (Y \cup X)$

... slow:

- Změna chyby podle domé váhy je rovna součtu chyb všech měřících přístrojů (podle domé váhy).

- Změna dýchací frekvence (example) podle vlny je rovna změně dýchací frekvence podle výstupu daného neuronu (do kterého vlna vchází), vynásobení určitým posuvným, na křivce je zobrazena derivována aktivita, a výstupem neuronu, ~~pro danou vlnu a vlnu~~ De kterého daná vlna vychází (o úroveň $\frac{1}{2}$ níže)
- Změna dýchací frekvence podle výstupu je rovna :

- pro výstupní neurony: rozdíl reálného a očekávaného výstupu
- pro vstupní neurony: součet přes všechny neurony, do kterých daný nerv. má (o 1 větší výs):

- Známa dĺžka podľa výstupu daného neurónu o prúde ~~na~~ vý, ktorá patrí medzi tieto 2 neuróny, ktorá určuje potenciál neurónu n (vstupná), na ktorú je aplikovaná derivovaná aplikácia fce

- Derivace aktivních funkcí

Logística sigmoide: $\sigma_j'(\xi_j) = \lambda_j y_j (1 - y_j)$

Hyperbolicity tangens: $\nabla_j(\xi_j) = a \cdot \tanh(b \cdot \xi_j)$

modifikasi' from
(stomach, metabolism)
primary

$$\nabla_j'(\xi_j) = \frac{b}{a} (a - y_j)(a + y_j)$$

- Gradient Descent algorithm

$$\epsilon_{ji} = 0 \quad (\text{na konci } \epsilon_{ji} = \frac{\partial E}{\partial w_{ji}})$$

for $(q = 1, \dots, p)$:

- 1) forward pass : - spočítat $y_j = g_j(\vec{w}_j; \vec{x}_2)$ pro všechny $j \in \mathbb{Z}$

- 2) backward pass: - spočítá $\frac{\partial E_2}{\partial n_i}$ pro všechny $j \in \mathbb{Z}$ pomocí Backpropagation

3) spözisaj $\frac{\partial E_R}{\partial w_{ji}} = \frac{\partial E_R}{\partial y_j} \cdot f'_j(x_j) \cdot y_i$ pro wärky w_{ji}

$$4) \varepsilon_{ji} = \varepsilon_{ji} + \frac{\partial E_2}{\partial m_{ji}}$$

$$\text{Výsledná } \varepsilon_{ji} = \frac{\partial E}{\partial w_{ji}}$$

• Backpropagation

Spôčítaj $\frac{\partial E_k}{\partial y_j}$ pre všetky $j \in Z$:

• $j \in Y \Rightarrow \frac{\partial E_k}{\partial y_j} = y_j - d_{kj}$

• $j \in Z - (Y \cup X) \Rightarrow$ predpokl., že $\frac{\partial E_k}{\partial y_n}$ je známe: ~~pro~~

$$\frac{\partial E_k}{\partial y_j} = \sum_{n \in j \Rightarrow} \frac{\partial E_k}{\partial y_n} \cdot \sigma'_n(\xi_n) \cdot w_{nj}$$

• Chain rule

$$\frac{\partial E_k}{\partial w_{12}} = \frac{\partial E_k}{\partial y_1} \cdot \frac{\partial y_1}{\partial \xi_1} \cdot \frac{\partial \xi_1}{\partial w_{12}} = \frac{\partial E_k}{\partial y_1} \cdot \sigma'_1(\xi_1) \cdot y_2$$

$$\frac{\partial E_k}{\partial w_{23}} = \dots = \frac{\partial E_k}{\partial y_2} \cdot \sigma'_2(\xi_2) \cdot y_3$$

$$\frac{\partial E_k}{\partial w_{34}} = \dots = \frac{\partial E_k}{\partial y_3} \cdot \sigma'_3(\xi_3) \cdot y_4$$

• Error functions


- Square error: $E(\vec{w}) = \sum_{k=1}^K E_k(\vec{w})$, kde

$$E_k(\vec{w}) = \frac{1}{2} \sum_{j \in Y} (y_j(\vec{w}, \vec{x}_k) - d_{kj})^2$$

- Mean square error (mse):

$$E(\vec{w}) = \frac{1}{K} \sum_{k=1}^K E_k(\vec{w})$$

..... minimovať chybu objazdu v danom bode



HEURISTIKY - GRADIENT DESCENT

• Momentum

Problém: Moc větší kroky mohou po sebětěmání náhodě (spontánním směrem) vykloupat na druhé straně opět nahoru. ~~V praxi bychom měli zvolit vhodnou hodnotu α a použít ji~~

Řešení: V každém kroku přičtena změna provedená minulým krokem (vyváženou faktorem α) → **HYBNOST**

$$\Delta \vec{w}(t) = -\epsilon(t) \cdot \sum_{\mathcal{R} \in T} \nabla E_{\mathcal{R}}(\vec{w}^{(t)}) + \alpha \cdot \Delta \vec{w}_{ji}^{(t-1)}$$

• Adaptivní se rychlost učení (learning rate)

- počítat s výšším (např. $\epsilon = 0.1$)
- později snížit (dohledat lokálního minima)

~~Průběh~~ Příklad:

- ~~error~~ Error $\downarrow \Rightarrow \epsilon \uparrow$

- Error $\uparrow \Rightarrow \epsilon \downarrow$

(chyba se může k náhodě ručně a rovn
to nemusí vadit - minimum je očiho
na korekci)

• Ada Grad

- každá váha má svůj learning rate (ϵ), který se updatuje samostatně:
 - málo mění se váhy \Rightarrow větší ϵ
 - hodně mění se váhy \Rightarrow menší ϵ
- problém: akumulace během celého procesu \Rightarrow RMSProp minimalizuje historii (exponenciálně)

POŽADAVKY NA AKTIVAČNÍ FUNKCE

- 1) diferencovatelná řešení (ne nutné vždy - RELU) \rightarrow gradient descent počítá s derivací
- 2) nelineární i lineární síť (lineární) je ekvivalentní jedno-vrstevné
- 3) monotónost bez lokálních extrémů
- 4) "lineární" jednodušší se učí \rightarrow tradeoff
.... dříve se používají co nejvíce lineární

Input preprocessing

- velké hodnoty mají výrazně větší vliv na trénink než malé

⇒ Standardizace:

- průměr = 0 (odečet průměru)
- odchylka = 1 (dělení standardní odchylkou)
(variance) "standard deviation"

- redukce dimenze: PCA (Principal Component Analysis)

• Inicializace váh interval $[-w; w]$; průměr = 0; odchylka = 1; d = počet vstupů do neuronu (rozptyl)

- příliš malá čísla ⇒ příliš lineární
- příliš velká čísla ⇒ ploché oblasti (rozestnutí)

Řešení: vybrat w takové, aby standardní odchylka je blízko přelomu mezi lineární a nelineární částí fce. (č. se rychle rozptylí do tohoto intervalu)

$$\Rightarrow w = \frac{\sqrt{3}}{\sqrt{d}} \Rightarrow \left[-\frac{\sqrt{3}}{\sqrt{d}}; \frac{\sqrt{3}}{\sqrt{d}} \right] \text{ rychle rozptylí vnitřní potenciál do intervalu } [-1; 1]$$

Glorot & Bengio inicializace

- pro lineární modely ideální


- lépe volitelněje boerword pass (než i počet neuronů nahoru, než jen dolů)

$$w = \sqrt{\frac{6}{m+n}}$$

Moderní aktivní funkce

- Hidden layers: ReLU

$$\sigma(x) = \max\{0, x\}$$



- Output neurons:

regrese → lineární / sigmoida

klasifikace → binární → logistická / sigmoida
→ tanh

→ n -ární → Softmax
(multi-class)

$$\sigma_j(x_j) = \frac{e^{x_j}}{\sum_{i \in Y} e^{x_i}}$$

... spolu se softmaxem se nejčastěji používá Cross-entropy jako error function

• Cross-entropy

$$E = -\frac{1}{N} \sum_{i=1}^N \sum_{j \in Y} [d_{ij} \ln(y_j) + (1-d_{ij}) \ln(1-y_j)]$$

... minimalizováním cross-entropy maximalizujeme likelihood
"Maximum likelihood principle"

• Proč je Cross-entropy lepší než MSE (mean square error)?

- Slovně:
- Když se MSE plete, ~~rozdíl~~ roste relativně rychle ve výpočtu rozhodnutí \Rightarrow trénink je pomalý.
 - Cross-entropy dává větší váhu odskokům směrem od správného rozhodnutí.

Formálně: binární klasifikace - $\{0,1\}$; 1 výstup neuron \rightarrow logistická sigmoida

MSE: $E_L^{mse} = (\sigma(wx_L) - d_L)^2$

$$\frac{\partial E^{mse}}{\partial w} = (\sigma(wx_L) - d_L) \cdot \sigma'(wx_L) \cdot x_L =$$

$$= (\sigma(wx_L) - d_L) \cdot \sigma(wx_L)(1 - \sigma(wx_L)) \cdot x_L$$

$d_L = 1$:

- pokud je ~~výstup správně~~ \rightarrow odečítáme tuto hodnotu od stávajícího valu
- je ovšem vnitřní potenciál
- přibližný (a my si jej chceme dostat do blízkosti 1), ~~MSE je lepší~~

$\frac{\partial E^{mse}}{\partial w}$ je malé číslo. Člen \bullet (wx_L je vnitřní potenciál $\Rightarrow \sigma(wx_L)$ je blízko 0).

Moc se nepohne \Rightarrow z tohoto spolehlivého stavu se nedostaneme.

CROSS-ENTROPY:

$$E_L^{cross}(w) = -d_L \ln(\sigma(wx_L)) + (1-d_L) \ln(1 - \sigma(wx_L))$$

$d_L = 1$: $\frac{\partial E_L^{cross}}{\partial w} = -\frac{1}{\sigma(wx_L)} \cdot \sigma'(wx_L) \cdot x_L = -\frac{1}{\sigma(wx_L)} \cdot \sigma(wx_L)(1 - \sigma(wx_L)) \cdot x_L =$

$= -(1 - \sigma(wx_L)) \cdot x_L = (\sigma(wx_L) - d_L) \cdot x_L$

\Rightarrow velké přibližné číslo \rightarrow odečítáme od valu \rightarrow posuneme "dopředu" \rightarrow odpovíme se

(pro $d_L = 0$ získáme to stejné)

• Cross-validation Early stopping (kdy skončíš s učním)

- rozdělit dataset na 3 části:

- Training set (60%) - k trénování použít pouze tyto data
- Validation (20%) - k ověření, kdy zastavit učení
- Test set (20%) - k otestování sítě (porovnání s jinými modely, ...)

→ Validation set se vždy "vzpíná" ⇒ na opravdové testování musíme

! VĚDY ! použít čerstvý, nedotčený dataset

• Dropout

- v určitém bodu gradient descent vybereme náhodně jen podmnožinu neuronů, které se používají do učení. Zbytek se pro toto kolo ignoruje

• Weight decay


- při určitém intervalu váh, vynásobíme koeficientem $0 < \alpha < 1$, a tím snížíme všechny váhy
- silné (důležité) přežijí a slabé (nedůležité) spadnou na 0

KONVOLUČNÍ SÍŤE

- Zpracování obrazu používá téměř výhradně konvoluční síť $k \times k$
- Každý neuron ve skryté vrstvě (hidden layer) je napojen na obrovské množství neuronů. Toto číslo se s každým dalším neuronem ve skryté vrstvě posouvá (obrovská ~~shift~~) a tvoří tak tzv. feature mapy.

stride
shift=2:

k=3:



↑
vstupní obrazek
(písmo) (např. písmo)

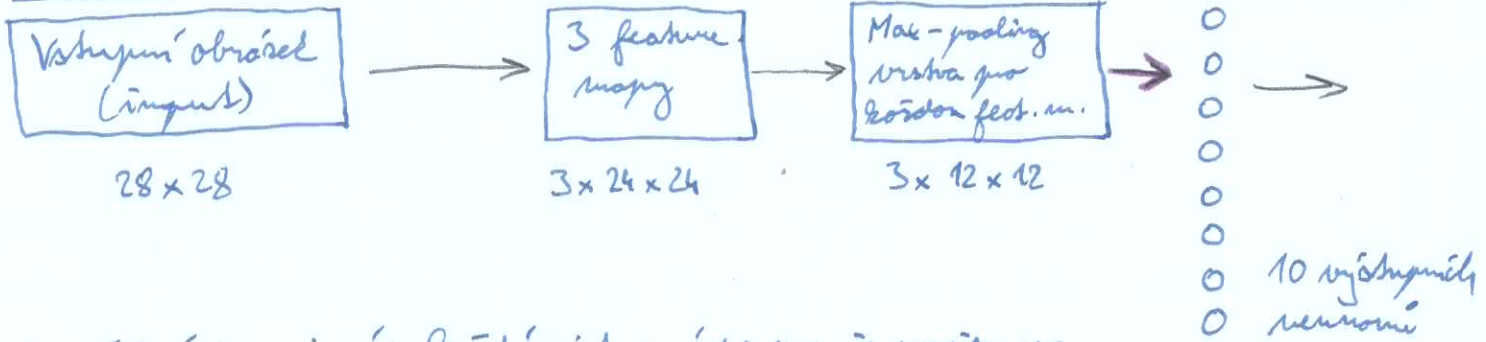
feature map:

- každý neuron ve vrstvě může spojit větší váhy
- mají pouze $k \times k$ (9) váh
- každá vrstva může mít několik podobných feature map
- každá feature mapa "hledá" v obrazech nějaký vzor

Pooling

- redukuje dimenze (každý neuron v pooling vrstvě je opět napojen na $m \times n$ čtvereček ve feature mapě a abstrahuje je do 1 výstupu)
- Max-pooling: bere maximum
- L2-pooling: odvozuje se z počtu 2. mocniny
- Avg-pooling: průměr
- nepřetváří se (mimořádně od konvol. mapy)


• Příklad



→ úplné propojení: Každý výstupní neuron je napojen na úplně všechny neurony a pooling vrstvu
 ⇒ Gradient descent pro všechno

• jak vypočítat $\frac{\partial E_k}{\partial w_{ji}}$?

Př.)



$$w_{24} = w_{36} = w_a$$

$$w_{25} = w_{37} = w_b$$

1 feature mapy:

②, ③

1 input vrstva:

y_4, y_5, y_6, y_7 (strana 2)

$$y_1 = \sigma_1(w_{12}y_2 + w_{13}y_3)$$

$$y_2 = \sigma_2(w_{24}y_4 + w_{25}y_5)$$

$$y_3 = \sigma_3(w_{36}y_6 + w_{37}y_7)$$

• poloměr w_a má vliv na y_2 i y_3
 ⇒ počítá se přes všechny neurony, které

$$\frac{\partial E_k}{\partial w_a} = \frac{\partial E_k}{\partial y_2} \cdot \frac{\partial y_2}{\partial w_a} + \frac{\partial E_k}{\partial y_3} \cdot \frac{\partial y_3}{\partial w_a} = \text{to ovlivní (které sdílí váhy)}$$

$$= \frac{\partial E_k}{\partial y_2} \cdot \sigma'_2 \cdot y_4 + \frac{\partial E_k}{\partial y_3} \cdot \sigma'_3 \cdot y_6$$

$$\frac{\partial E_k}{\partial w_{ji}} = \sum_{n \in \text{output}} \frac{\partial E_k}{\partial y_n} \cdot \sigma'_n(y_n) \cdot y_j$$

Opovrdit tu má být y_n ?
 - ve složce to tak je (str. 189), ale příklad a tabulka ukazuje něco jiného

• Backpropagation

- pro $j \in Y$: $\frac{\partial E_k}{\partial y_j} = y_j - d_{kj}$ (pro MSE)

- pro $j \in Z \setminus Y$, kde $j \rightarrow$ je konvoluční vrstva nebo dense vrstva: (úplně propojená)

$$\frac{\partial E_k}{\partial y_j} = \sum_{n \in Y} \frac{\partial E_k}{\partial y_n} \cdot \sigma'_n(y_n) \cdot w_{nj}$$

- pro $j \in \mathbb{Z} \setminus Y$, kde $j \rightarrow$ je max-pooling vrstva, pro $j \rightarrow = \{i\}$ pro každý 'max' neuron:

$$\frac{\partial E_L}{\partial y_j} = \begin{cases} \frac{\partial E_L}{\partial y_{ji}} & \text{pokud } j \text{ je ten maximální neuron} \\ 0 & \text{jinak} \end{cases}$$

DEEP MLP

PRO: - lepší výsledky
- řešení problémů
- 1 vrstva může být neefektivní

PROTI: - vanishing gradients
- rychlé přetížení (overfit)

Vanishing gradients

$$\frac{\partial E_L}{\partial y_j} = \sum_{M \in j \rightarrow} \frac{\partial E_L}{\partial y_M} \cdot \boxed{\sigma'_n(y_M)} \cdot w_{Mj}$$

pro standardní aktivční fce (logistická, sigmoid, tanh, ...) je σ'_n menší než 1 \Rightarrow opakovaným násobením gradient stále mizí \Rightarrow \Rightarrow v mizivých vrstvách to není vůbec potřeba

Předtrénování MLP pomocí RBM

- rozdělí 2 sousední vrstvy MLP můžeme považovat ka RBM (Restricted Boltzmann Machine) B_i odpovídá vrstvě i a $i-1$ ($B_1 = \text{input} + 1. \text{ vrstva}$)

- 1. fáze učení (unsupervised pretraining):

- bereme jen vstupy (ignorujeme očíslování výstupu)
- na náhodné podmnožině kvantitativní vstupy nastavujeme B_i (pro $i=1, \dots, L$) pomocí RBM algoritmu
- tímto vlastně inicializujeme váhy MLP tak, že již v sobě obsažují jistou dávku informace (vzrostl) z dat. - "nejlepší možné počáteční domněnky"
- postupujeme od spodu - rozdělou předtrénovanou podčást sítě (1. vrstva, 1. dvě vrstvy, ...) použijeme k transformaci dat pro následující vrstvu (2., 3., ...)

REKURENTNÍ SÍŤE

Rekurentní MLP (se synchron):

- vstup (input): \vec{x}


- stav: \vec{h}

- output: \vec{y}

- matice: U, W, V
vše

$$\vec{h} = \sigma(U\vec{x} + W\vec{h}) \quad \text{... sigmoidal / ReLU}$$


$$\vec{y} = \sigma(V\vec{h}) \quad \text{... softmax / sigmoidal}$$



~~usnadnění~~

=> ke zpracování sekvence vstupů => časové řady odd. (zpracování řádků)

Unfolding



+1 dimenze

vstup = sekvence vektorů
výstup = sekvence vektorů

\vec{h}_t je ~~na~~ paměť sítě

$$\vec{h}_t = \sigma(U\vec{x}_t + W\vec{h}_{t-1})$$

$$\vec{y}_t = \sigma(V\vec{h}_t)$$

matice U, V, W jsou pro všechny stejné

Learning

- training sample (1 příklad): (x, d)

$$x = \vec{x}_1, \dots, \vec{x}_T \quad (\text{sekvence vstupů})$$

$$\vec{x}_t = (x_{t1}, \dots, x_{tN})$$

(to stejné pro d - výstupy)

- rozbalení (unfolding) pro dané x vytvoří sekvenci vnitřních stavů:

$$\vec{h}_0, \vec{h}_1, \vec{h}_2, \dots, \vec{h}_T$$

$$\text{rozdě } \vec{h}_t = (h_{t1}, \dots, h_{tH})$$

$$\vec{h}_0 = (0, \dots, 0)$$

- sekvence výstupů: $\vec{y}_1, \dots, \vec{y}_T$ rozděl $\vec{y}_t = (y_{t1}, \dots, y_{tM})$

Chybová funkce:

$$E(x, d) = \sum_{t=1}^T \sum_{k=1}^M (y_{tk} - d_{tk})^2$$

-> online verze (pro minimální maximální
příděl ještě jednu sumu)

• Backpropagation

$\nabla E_{(x,d)}(\vec{w}^{(t)})$ ----- vektor všech parciálních derivací $\frac{\partial E_{(x,d)}}{\partial w_{ji}}$

1) pro nalezit derivace podle w_{ji} na derivace podle y_j :

$$\frac{\partial E_{(x,d)}}{\partial w_{ji}} = \sum_{n \in \text{hidden}} \frac{\partial E_{(x,d)}}{\partial y_n} \cdot \sigma'_n(\xi_n) \cdot y_j$$

2) pro $j \in Y$: (MSE)

$$\frac{\partial E_{(x,d)}}{\partial y_j} = y_j - d_j$$

3) pro $j \in Z \setminus Y$:

$$\frac{\partial E_{(x,d)}}{\partial y_j} = \sum_{n \in j \rightarrow} \frac{\partial E_{(x,d)}}{\partial y_n} \cdot \sigma'_n(\xi_n) \cdot w_{nj}$$

RNN:

$$\frac{\partial E_{(x,d)}}{\partial h_{tL}} = \sum_{L'=1}^N \frac{\partial E_{(x,d)}}{\partial y_{tL'}} \cdot \sigma' \cdot V_{L'L} + \sum_{L'=1}^H \frac{\partial E_{(x,d)}}{\partial h_{(t+1)L'}} \cdot \boxed{\sigma' \cdot W_{L'L}}$$

$$\frac{\partial E_{(x,d)}}{\partial V_{L'L}} = \sum_{L'=1}^T \frac{\partial E_{(x,d)}}{\partial y_{L'L}} \cdot \sigma' \cdot h_{L'L}$$

$$\frac{\partial E_{(x,d)}}{\partial W_{L'L}} = \sum_{L'=1}^T \frac{\partial E_{(x,d)}}{\partial h_{L'L}} \cdot \sigma' \cdot h_{(L-1)L'}$$

$$\frac{\partial E_{(x,d)}}{\partial U_{L'L}} = \sum_{L'=1}^T \frac{\partial E_{(x,d)}}{\partial h_{L'L}} \cdot \sigma' \cdot x_{L'L}$$

• ~~ste~~ spálky is case = vanishing gradient
nebo exploding
 \Rightarrow řešení: LSTM
chrána
co nízkože 1, jinak


LSTM

- každý neuron je vlastně komplexní 'mašinou'


o..... hadamardův produkt (národní go komparátor, ne dot produkt)

$$\vec{h}_t = \vec{h}_{t-1} \odot \vec{f}_t + \vec{i}_t \odot \vec{c}_t$$

• RNN vs LSTM
(banka)



LSTM



$$(\vec{h}_t) \vec{h}_t = \vec{c}_t \odot \vec{f}_t + \vec{i}_t \odot \vec{c}_t$$

$$\vec{c}_t = \vec{f}_t \odot \vec{c}_{t-1} + \vec{i}_t \odot \vec{c}_t$$

$$\vec{c}_t = \sigma_c(W_c \cdot \vec{h}_{t-1} + U_c \cdot \vec{x}_t)$$

$$\vec{f}_t = \sigma_f(W_f \cdot \vec{h}_{t-1} + U_f \cdot \vec{x}_t)$$

$$\vec{i}_t = \sigma_i(W_i \cdot \vec{h}_{t-1} + U_i \cdot \vec{x}_t)$$

$$\vec{o}_t = \sigma_o(W_o \cdot \vec{h}_{t-1} + U_o \cdot \vec{x}_t)$$

output

memory

new memory contents

output gate

forget gate

input gate

- kontroluje, kolik informace má přivést z historie, kolik má 'zapomenout', kolik má 'vstoupit' z nových dat, kolik poslat dál, atd.

KOHONENOVY MAPY

Vector quantisation

- pro každý input \vec{x} , máme nejbližší střed $\vec{w}_c(\vec{x})$:

$$c(\vec{x}) = \arg \min_{i=1, \dots, k} \{ \|\vec{x} - \vec{w}_i\| \}$$

- následně minimalizujeme dybu:

$$E = \int \|\vec{x} - \vec{w}_{c(\vec{x})}\|^2 f(\vec{x}) d\vec{x}$$

→ chceme nahradit všechny objemy \vec{x} stedy \vec{w} tak, abychom snížili dimenzi a zároveň dobře popsalí dataset


→ co nejvíce středů v hustých oblastech, co nejmenší v řídkých

jak to vyřešit? \Rightarrow k-means (Lloyd's algorithm)
 \Rightarrow Kohonenovy mapy

ONLINE	
NE	! - potřebujeme celý dataset
ANO	!

Z pohledu NN

1 vrstva:



vstupní objemy:
 x
 výhledové souřadnice středů:
 w

neuron Kohonenovy mapy jsou stále propojeny aktivním propojením, přerušeno na standardním propojování (váhy, ...)

pro vstup $\vec{x} \in \mathbb{R}^n$ a $k=1, \dots, k$:

$$y_k = \begin{cases} 1 & k = \arg \min_{i=1, \dots, k} \|\vec{x} - \vec{w}_i\| \\ 0 & \text{jinak} \end{cases}$$

Activity

• Learning

- bereme s nízkou topologií síť, která je "malá" a klasickou strukturou
→ propojení neuronů do minisítě

$d(c, z) = \text{nejmenší vzdálenost } z \text{ k } c$

topological neighbourhood neuronu c o velikosti s :

$$N_s(c) = \{z \mid d(c, z) \leq s\}$$

• Krok učebního algoritmu

$$\vec{w}_z^{(t)} = \begin{cases} \vec{w}_z^{(t-1)} + \theta \cdot (\vec{x}_d - \vec{w}_z^{(t-1)}) & \text{pro } z \in N_s(c(\vec{x}_d)) \\ \vec{w}_z^{(t-1)} & \text{jinak} \end{cases}$$

$$\text{Zde } c(\vec{x}_d) = \arg \min_{i=1, \dots, h} \|\vec{x}_d - \vec{w}_i^{(t-1)}\|$$

$\theta \in \mathbb{R}$
 $s \in \mathbb{N}_0$ } parametry, které se během učení mohou měnit

• V Práci

2 fáze: • coarse phase: - cca 1000 iterací

- learning rate θ : od 0.1 do 0.01 (postupně)
- sousedství neuronů: počítáno velikostí síťového okna, postupně zmenšovat

• fine tuning - cca 500 x počet neuronů

- θ blízko 0,01 (jinak je pravděpodobnost defektů)
- jen malá sousedství neuronů

• Klasifikace pomocí kolobracových map

1) Nahrání mapy na vstupních datech (ignorování šumu)

2) Bratř neuronů šumů: - řadí šumů vzhledem k neuronu, který rostl nejvíce
jeho je jeho instancí (obrazem)

3) dokončení učení (fine tune) na pomoci LVC (přesněji)

Použití: - spočítat pro každý vstup \vec{x} nejblíže střed a vrátit jeho třídu

• LVQ

pro každý tréninkový příklad:

- najdi nejbližší neuron:

- pokud je ~~spájen~~ s křídla správně, posun střed blíže k novému vzorku
- pokud je křídla špatně, posun střed dále od nového vzorku

$$\vec{w}_c(s) = \begin{cases} \vec{w}_c(s-1) + \alpha (\vec{x}_s - \vec{w}_c(s-1)) & d_s = N_c \\ \vec{w}_c(s-1) - \alpha (\vec{x}_s - \vec{w}_c(s-1)) & d_s \neq N_c \end{cases}$$

HOPFIELD NETWORK

- Křídla - kompletní graf
- všechny neurony jsou zároveň vstupní i výstupní
- váhy jsou symetrické $w_{ji} = w_{ij}$
- Pokud síť dostane nově vzor, měla by roztavit a dále se neměnit.
- Pokud síť dostane známý vzor, měla by se dostat do stavu odpovídajícímu nejbližšímu známému vzorku (vstup)
- Training set je jen ^{možná} vektorů $\vec{x}_i \in \{-1, 1\}^n$
- Hebb's rule: neurony, které dvojice neuronů minují často stejnou hodnotu

$$w_{ji} = \sum_{k=1}^K x_{kj} x_{ki} \quad 1 \leq j \neq i \leq n$$

... pokud jsou x_{kj} a x_{ki} stejné (obě 1 nebo obě -1), výjde velice pozitivní číslo \Rightarrow jejich spojení by mělo být silné.

... pokud jsou rozdílné \Rightarrow výjde velice negativní číslo \Rightarrow jejich spojení by mělo být slabé

• Activity: - nejprve nastavíme neurony na vstupní síť

- cyklicky upravení stavu neuronů:

1) vnitřní potenciál:

$$\xi_j^{(s)} = \sum_{i=1}^n w_{ji} y_i^{(s)}$$

$$2) \quad y_j^{(s+1)} = \begin{cases} 1 & \xi_j^{(s)} > 0 \\ y_j^{(s)} & \xi_j^{(s)} = 0 \\ -1 & \xi_j^{(s)} < 0 \end{cases}$$

\rightarrow tento proces roztaví, na konci vstup

$$y_j^{(s+m)} = y_j^{(s^*)} \quad (j=1, \dots, n)$$

- Energie (potenciální) pro kódový stav $\vec{y} \in \{-1, 1\}^n$

$$E(\vec{y}) = -\frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n w_{ji} y_j y_i$$

- stav s malou energií je méně stabilní (méně rovnovážný "dělá ručník" svůj stav)
- stav s velkou energií je méně stabilní \Rightarrow large (positive) $w_{ji} y_j y_i$ je stabilní
small (negative) $w_{ji} y_j y_i$ není stabilní
- Energie se během procesu nezvyšuje

• Phansons

- = lokální minimum energetické fce, stav, který odpovídá s ~~lok~~ minimálnímu průměrnému
- malou být "odmáčení" (inverted Hebb's rule):

$$w'_{ji} = w_{ji} - x_i x_j$$

• Kapacita Hopfieldovy sítě

$$p \leq n / (4 \log n)$$

p = počet tréninkových příkladů uložit se
 n = počet neuronů

• Boltzmann activity

- místo chování cyklicky dohoda, v každém kroku vybereme náhodně neuron:
~~neuron~~ inner potential:

$$\xi_j^{(s)} = \sum_{i=1}^n w_{ji} y_i^{(s)}$$

poté vyber náhodně 1 nebo -1 ($y_j^{(s+1)} \in \{-1, 1\}$)


$$P[y_j^{(s+1)} = 1] = \sigma(\xi_j^{(s)})$$

žde

$$\sigma(\xi) = \frac{1}{1 + e^{-2\xi/T(t)}}$$

$T(t)$ je teplota v čase t

logická signatura



- vysoká teplota \Rightarrow náhodné chování


- nízká teplota \Rightarrow stabilní chování

- Boltzmann Activity = Hopfield network + random noise

- Energie může posloužit na vyšší úrovni, v závislosti na teplotě

• Hopfield networks - příklad

2 neurons:



- pravděpodobnost přechodu a :

$$P[a] = \frac{1}{2} \cdot P_1^a$$

ps. i.e. vybere neuron 1


$$P_1^{(1)} = w_{12} \cdot 1 \Rightarrow P_1^a = \frac{1}{1 + e^{-2w_{12}}}$$

tepota je 1

\Rightarrow velké váhy \rightarrow neuron dříve s stejné hodnoty

\Rightarrow malé váhy \rightarrow neuron dříve s různé hodnoty

4 stavy:



P_1^a je pravděpodobnost 1 u neuronu 1

• Simulated annealing

- k lepšímu dosažení glob. minima energie

• začít s vysokou teplotou a postupně ji snižovat

BOLTZMAN MACHINE

• Architektura

- NN s cizími vstupem a neovlivňovanými výstupy

- jinak vlastně stejné jako Hopfield N.

• Aktivita:

- v každém kroku $k+1$:

1) vyber náhodně neuron

2) spočítaj vnitřní potenciál

$$g_j^{(k)} = \sum_{i \in J} w_{ji} y_i^{(k)}$$

3) vyber $y_j^{(k+1)} \in \{-1, 1\}$ náhodně

$$P[y_j^{(k+1)} = 1] = \sigma(g_j^{(k)}) \quad \dots \quad \sigma = \boxed{\frac{1}{1 + e^{-x}}}$$

\Rightarrow definuje pravděpodobnostní rozložení vektorem $\{-1, 1\}^N$

\rightarrow když necháme BN běžet dostatečně dlouho, relativní četnost jednotlivých stavů bude odpovídat na minimální stav

\rightarrow bylo čteno ležeme jako pravděpodobnosti jednotlivých stavů

\rightarrow během učení vstane pravděpod. rozložení stavů $\{-1, 1\}^N$ a podle nich adaptujeme váhy tak, aby odpovídaly dané pravděp.

• Equilibrium

- fixovaná teplota
- dát jsou více neuronů i

pravidlo, že stav vidět. neuronů
v term. equil. je α

• Hidden neurons

- rozdělíme N na 2 množiny:
 - visible V
 - hidden H

$$\alpha \in \{-1, 1\}^{|V|}$$

$$p_V(\alpha) = \sum_{\beta \in \{-1, 1\}^{|H|}} p_N(\alpha, \beta)$$

~~- a je jst, že stav viditelných neuronů je v termální rovnováze~~

given target prob.

$$E(W) = \sum_{\alpha \in \{-1, 1\}^{|V|}} p_d(\alpha) \ln \frac{p_d(\alpha)}{p_V(\alpha)}$$

current learned prob.

• Maximum likelihood

$$p_d(\alpha) = \#(\alpha, T) / m, \text{ kde } \#(\alpha, T) \text{ je počet výskytů } \alpha \text{ v } T$$

$m = |T|$

naším cílem je najít konfiguraci \vec{w} takovou, že $p_V \approx p_d$

likelihood:

$$L(T) = \prod_{i=1}^m P_V(\vec{x}_i) \leftarrow \text{toho chceme maximalizovat}$$

• Gradient descent

RESTRICTED BOLTZMAN MACHINE

• Kompletní bipartitní graf



• stav neuron -1 a 1, ale $\vec{y} \in \{0, 1\}^{|H|}$

• bias: možo y_0 je stále 0

• Activity

- v rozdělném ~~tréninku~~ předním průchodu: náhodně vyber hodnoty všech hidden neuronů
- v rozdělném ~~tréninku~~ zadním průchodu: náhodně vyber hodnoty všech visible neuronů

- pro každé $j \in H$:

$$P[y_j^{(L+1)} = 1] = \frac{1}{1 + \exp(-w_{j0} - \sum_{i \in V} w_{ji} y_i^{(L)})}$$

- pro $j \in V$:

to stejné, ale $\sum_{i \in H}$